

Teitter 情感文字分析計劃書

410711321 統計碩二張子恩

April 2, 2025

1 資料介紹

1.1 資料來源

- 資料集名稱：Sentiment140 資料集
- 來源網址：<https://www.kaggle.com/datasets/kazanova/sentiment140>
- 提供單位：資料由 Kaggle 提供，內容取自 Twitter 的公開推文。
- 資料數量：包含 1,600,000 條推文，這些推文已被標註為正面、中性或負面情感。
- 用途：該資料集適合用於情感分析任務，包括自然語言處理（NLP）與機器學習模型訓練。

1.2 資料欄位說明

欄位名稱	描述	類型
sentiment	推文的情感標籤：0 = 負面，4 = 正面	int64
id	推文的唯一識別碼	int64
date	推文的發布日期，格式為「星期幾月/日/年時間」	object
flag	查詢標籤：如果無查詢，則值為 NO_QUERY	object
user	推文作者（Twitter 使用者名稱）	object
text	推文內容（原始文字）	object

1.3 前五筆資料

sentiment	id	date	query	user_id	text	Preprocessed Text
1	0	1467810369	Mon Apr 06 22:19:45 PDT 2009	NO_QUERY	_TheSpecialOne_	@twitchoof http://twitpic.com/2y1d - Awww, L... Awww, I summer shoulda get David Car Day...
2	0	1467810672	Mon Apr 06 22:19:49 PDT 2009	NO_QUERY	scotthamilton	Is upset that he can't update his Facebook by... upset I update Facebook better cry result S...
3	0	1467810917	Mon Apr 06 22:19:53 PDT 2009	NO_QUERY	matycuz	@Kenschen I died many times for the ball. Man... dive time ball manage size 50 rest bound...
4	0	1467811184	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	ERICP	my whole body feels itchy and like its on fire
5	0	1467811193	Mon Apr 06 22:19:57 PDT 2009	NO_QUERY	Karol	@tripsweirdedoes on, it's not behaving at all... s behave m, mad L...

Figure 1: 前五筆 Twitter 情感分析資料樣本

此圖顯示了資料集中前五筆情感分析樣本，包括情感標籤、唯一識別碼、發布日期、查詢標籤、作者名稱、原始內容以及 Preprocessed Text：預處理後的推文內容（清理並去除多餘符號與雜訊），其中 Preprocessed Text 等等會提到如何處理。

2 資料前處理

資料欄位中的 Preprocessed Text 為在進行情感分析之前，我們需要對推文提取關鍵字出來。以下是一段使用 Python 程式碼進行文字資料清理與處理的範例：

```
def preprocess(text):  
    doc = nlp(text)  
    filtered_tokens = []  
    for token in doc:  
        if token.is_stop or token.is_punct:
```

```

        continue
    filtered_tokens.append(token.lemma_)
return " ".join(filtered_tokens)

```

這段程式碼的主要功能為：去除停用詞（Stop Words）：如“the”、“is”等不具備語意的常見詞、忽略標點符號（Punctuation）：移除句中的標點符號以專注於語意分析、詞形還原（Lemmatization）：將詞彙轉換為其基本詞形，例如將“running”轉換為“run”、返回處理後的文本：最後，將清理後的詞彙重新組合成一個句子，以利後續模型處理。

3 資料分析敘述統計




Figure 2: 負面評論與正面評論次數

這張圖表展示了我們數據集中正面評論和負面評論的分佈情況，可以看出這兩類評論的數量相對接近，呈現出較為均衡的狀態。這種均衡的分佈對於我們的情感分析具有重要意義。首先，這個模型的訓練提供了良好的數據基礎，因為數據分佈的平衡性有助於避免模型對某一類別產生偏倚，從而提升預測的準確性。其次，這種分佈也反映了用戶在社交媒體上的多樣化觀點，說明無論是正面情緒還是負面情緒，用戶都願意表達自己的看法。




Figure 3: 負面文字雲

上圖文字雲展示了負面推文中最常出現的詞語，突出了例如「工作」、「錯過」和「一天」這些詞語。




Figure 4: 正面文字雲

上圖則展示了正面推文的文字雲，包含了一些反映正面情緒和態度的常見詞語。




Figure 5: 正面與負面隨著時間推演

圖 1 呈現了一天內各時段推文情感分佈的變化趨勢，紅色虛線代表正面情感推文頻率，藍色虛線則代表負面情感推文頻率。從圖中可以看到，正面情感推文在凌晨至早晨（00:00-06:00）逐漸減少，在 07:00 左右達到一天中的最低點，隨後開始回升，並於晚上（21:00-23:00）達到高峰。負面情感推文的變化則與正面情感有一定差異，清晨（06:00-09:00）推文頻率明顯高於正面情感，可能反映了早晨壓力情境（如通勤）的影響。從中午到下午（10:00-16:00），負面情感與正面情感的推文頻率趨於平穩，而晚間（20:00-23:00），兩者的頻率都顯著上升。這些結果揭示了用戶在一天不同時段的情感表達特徵。例如，正面情感的高峰出現在晚上時段，可能與用戶在結束一天的工作或活動後，傾向於分享積極情緒有關。而負面情感的高峰則集中於早晨，可能與當時的高壓情境（如準備工作、通勤困難等）密切相關。中午和下午時段的平穩表現則表明，用戶在該時段的情感表達相對較少受外界事件的影響，呈現一種穩定的情感狀態。

4 機器學習

此節旨在通過機器學習方法分析與預測推文的情感極性，探索不同模型在情感分類任務中的性能表現。本節包括數據前處理、模型建構及評估，並針對以下任務進行詳細探討：

- 預測推文的情感（sentiment）：0 表示負面，2 表示中性，4 表示正面。
- 分析哪些特徵（如文本中的詞彙或結構）對情感預測有顯著影響。

透過隨機森林（Random Forest）、樸素貝葉斯（Naive Bayes）、決策樹（Decision Tree）、以及卷積神經網絡（CNN）等模型，我們不僅對數據進行深入挖掘，還提供了具體的應用場景與改進建議。本節將展示模型的調參過程、預測結果以及相應的性能評估，為後續分析提供科學依據。

我們使用 `train_test_split` 將數據集拆分為訓練集與測試集，如果訓練集為慣例 7 成，會造成檔案過大，電腦暫存記憶體無法負荷，故改成六成：

- 訓練集（60%）：用於訓練模型，變數為 `X_train` 和 `y_train`。

- 測試集 (40%)：用於評估模型，變數為 X_{test} 和 y_{test} 。

調整訓練集比例的原因如下：

- 減少暫存記憶體的使用，防止因數據過大導致電腦運算中斷。
- 確保測試集仍具有足夠數據量，用於模型性能的有效評估。

我們採用了以下四種模型進行情感分析：

- 隨機森林 (Random Forest)：通過多棵決策樹的投票機制進行分類，適合處理高維數據。
- 朴素貝葉斯 (Naive Bayes)：基於條件概率的簡單且高效的分類模型，適用於文本分類任務。
- 決策樹 (Decision Tree)：通過樹狀結構進行分類，具有良好的解釋性。
- 卷積神經網絡 (CNN)：用於提取文本的高維特徵，適合大規模數據和深度學習任務。

5 隨機森林

隨機森林是一種基於多棵決策樹進行分類或回歸的機器學習方法，其核心思想是通過集成學習 (Ensemble Learning) 提升模型的預測能力。具體而言，在情感分析中，隨機森林可以幫助我們：

- 分類推文情感 (正面、中性或負面)。
- 減少單一決策樹的過擬合風險，提升模型的穩健性。
- 通過特徵重要性評估，分析哪些詞彙或特徵對情感分類的影響最大。

```

Training Accuracy: 0.9859780912096048
Training Loss: 0.1527
Classification Report:

```

	precision	recall	f1-score	support
0	0.99	0.99	0.99	636940
1	0.99	0.99	0.99	635426
accuracy			0.99	1272366
macro avg	0.99	0.99	0.99	1272366
weighted avg	0.99	0.99	0.99	1272366

Figure 6: 隨機森林 train report

```

Testing Accuracy: 0.7643354752713052
Testing Loss: 0.5326
Classification Report:

```

	precision	recall	f1-score	support
0	0.76	0.78	0.77	158502
1	0.77	0.75	0.76	159590
accuracy			0.76	318092
macro avg	0.76	0.76	0.76	318092
weighted avg	0.76	0.76	0.76	318092

Figure 7: 隨機森林 test report

上面兩圖分別展示了隨機森林模型在 訓練集和 測試集上的分類性能與特徵重要性，幫助我們理解模型在不同數據集上的表現。

在訓練集中，模型的分類準確率高達 **98.59%**，損失函數值為 **0.1527**，表現非常出色。根據分類報告，無論是負面情感（標籤 0）還是正面情感（標籤 1），其 Precision、Recall 和 F1-Score 均為 **99%**。這表明模型能夠準確地對訓練數據進行分類。然而，過高的性能也提示模型可能過於依賴訓練數據，存在過擬合的可能性。

在測試集中，模型的準確率下降至 **76.43%**，損失函數值為 **0.5326**。測試集的分類性能顯示，負面情感（標籤 0）的 Precision 為 **76%**，Recall 為 **78%**，F1-Score 為 **77%**；正面情感（標籤 1）的 Precision 為 **77%**，Recall 為 **75%**，F1-Score 為 **76%**。總體來說，測試集的平均分類性能為 **76%**，表明模型在泛化能力上還有改進空間。



Figure 8: 隨機森林 train 混淆矩陣




Figure 9: 隨機森林 test 混淆矩陣

上面兩圖分別展示了隨機森林模型在測試集和訓練集上的混淆矩陣結果。從第一張圖中可以看到，模型在測試集上將負面情感（標籤 0）正確分類為負面的樣本數為 123096，而正面情感（標籤 1）正確分類為正面的樣本數為 120033。然而，模型仍存在一定的錯誤分類，其中將負面情感錯誤分類為正面的樣本數為 35406，將正面情感錯誤分類為負面的樣本數為 39557。整體來看，測試集的分類性能顯示模型具有一定的準確率，但正負兩類之間的錯誤分類比例需要進一步改進。對比之下，第二張圖

展示了模型在訓練集上的表現。模型將負面情感正確分類為負面的樣本數高達 628075，而正面情感正確分類為正面的樣本數為 626450。同時，訓練集的錯誤分類數明顯少於測試集，其中將負面情感錯誤分類為正面的樣本數為 8865，而將正面情感錯誤分類為負面的樣本數僅為 8976。這表明模型在訓練數據上的分類非常精確，但也顯示出模型可能存在過擬合現象。綜合測試集與訓練集的結果，訓練集上極高的準確率與測試集上明顯的性能下降形成對比，揭示了模型在泛化能力上的不足。測試集中的錯誤分類顯示，模型在處理未見數據時的表現仍需改進。特別是正負兩類情感的錯誤分類比例接近，說明模型對這兩類的區分能力尚可，但未能完全捕捉其特徵差異。為了提升模型的分類性能，未來可以考慮增加訓練數據的多樣性，或者通過調整模型的超參數（例如樹的深度或樣本特徵的使用比例）來減少過擬合。同時，針對測試集的錯誤分類進行深入分析，找出數據中可能影響模型判斷的特徵或模式，將有助於進一步優化模型的泛化能力。

6 Naive Bayes

Naive Bayes（朴素貝葉斯）是一種基於貝葉斯定理的機器學習算法，廣泛應用於文本分類等自然語言處理任務。該模型的核心假設是特徵之間相互條件獨立，這使其在數據維度較高的情況下依然能保持高效性。特別是對於情感分析這類分類問題，Naive Bayes 具有簡單、快速且效果穩定的特點。

本次分析中，我們使用 **Multinomial Naive Bayes** 模型處理文本數據，主要應用於推文的情感分類任務。該模型利用文本的詞頻特徵，結合情感標籤（正面或負面），學習文本與情感的對應關係，進而實現對新推文的情感預測。

```

Training Accuracy: 0.7480377753140084
Classification Report:

```

	precision	recall	f1-score	support
0.0	0.75	0.75	0.75	477674
1.0	0.75	0.74	0.75	476600
accuracy			0.75	954274
macro avg	0.75	0.75	0.75	954274
weighted avg	0.75	0.75	0.75	954274

Figure 10: Naive Bayes train report

```

Testing Accuracy: 0.7470747456710637
Classification Report:

```

	precision	recall	f1-score	support
0	0.74	0.75	0.75	317768
1	0.75	0.74	0.75	318416
accuracy			0.75	636184
macro avg	0.75	0.75	0.75	636184
weighted avg	0.75	0.75	0.75	636184

Figure 11: Naive Bayes test report

上面兩張圖分別展示了 Multinomial Naive Bayes 模型在測試集和訓練集上的分類性能，包含準確率、Precision、Recall 和 F1-Score 等評估指標。在測試集上，模型的整體準確率為 **74.71%**。負面情感（標籤 0）的 Precision 為 **74%**，Recall 為 **75%**，F1-Score 為 **75%**；正面情感（標籤 1）的 Precision 為 **75%**，Recall 為 **74%**，F1-Score 為 **75%**。這表明，模型在兩類情感之間的分類性能相對均衡，無明顯的偏差。測試集的宏平均（Macro Avg）和加權平均（Weighted Avg）均為 **75%**，進一步證明了模型的穩定性。

在訓練集上，模型的整體準確率略高於測試集，為 **74.80%**。負面情感（標籤 0）的 Precision、Recall 和 F1-Score 均為 **75%**，而正面情感（標籤 1）的 Precision 為 **75%**，Recall 為 **74%**，F1-Score 同樣為 **75%**。這表明模型對訓練數據的學習效果與測試數據的表現相當一致，沒有明顯的過擬合現象。

綜合來看，Multinomial Naive Bayes 模型在訓練集和測試集上的性能接近，這說明模型具有良好的泛化能力。此外，兩類情感的 Precision 和 Recall 相對平衡，這意味著模型對正負情感的分類不偏向於某一類。儘管準確率未達到非常高的水平，但作為一個高效且輕量的基線模型，Naive Bayes 在文本分類任務中仍表現出可靠的性能。




Figure 12: Naive Bayes train 混淆矩陣




Figure 13: Naive Bayes test 混淆矩陣

上面兩張分別展示了 Multinomial Naive Bayes 模型在測試集與訓練集上的混淆矩陣結果，用於評估模型在不同數據集上的分類能力。

在測試集上，模型的分類結果顯示，負面情感（標籤 0）中有 **239279** 條樣本被正確分類，而 **78489** 條樣本被錯誤分類為正面情感（標籤 1）。正面情感（標籤 1）中有 **235998** 條樣本被正確分類，而 **82418** 條樣本被錯誤分類為負面情感（標籤 0）。這表明模型對於兩類情感的分類存在一定的錯誤，特別是在處理測試數據時。

在訓練集上，模型的分類結果顯示，負面情感（標籤 0）中有 **359553** 條樣本被正確分類，而 **118121** 條樣本被錯誤分類為正面情感（標籤 1）。正面情感（標籤 1）中有 **354280** 條樣本被正確分類，而 **122320** 條樣本被錯誤分類為負面情感（標籤 0）。相較於測試集，訓練集的分類結果顯示出模

型在已知數據上的表現更加穩定，錯誤分類數量較少。

從混淆矩陣的結果可以看出，Naive Bayes 模型對於正面和負面情感的分類具有一定的能力，但在測試集上的分類準確率低於訓練集，可能受到數據分佈差異的影響。同時，模型在兩類情感上的錯誤分類數量相對接近，表明模型對正負情感的區分沒有明顯的偏倚。

6.1 討論

綜合以上分析，Multinomial Naive Bayes 模型在訓練集和測試集上的性能表現接近，顯示出一定的泛化能力。從 Precision 和 Recall 的結果來看，模型對正面和負面情感的分類表現相對平衡，沒有明顯的偏倚。雖然模型的準確率未達到非常高的水準，但作為一個高效且輕量的基線模型，Naive Bayes 在文本分類任務中仍展現出可靠且穩定的性能。

混淆矩陣進一步提供了對分類性能的直觀理解，顯示了正確分類和錯誤分類的數據分佈情況。這些結果表明，Naive Bayes 模型能快速學習文本數據的特徵並進行有效分類。然而，為了進一步提升分類準確性，未來可以考慮改進特徵提取方式（例如採用更具代表性的特徵如 TF-IDF），或者嘗試引入其他更為複雜的模型，以優化文本分類任務的整體效果。

7 Decision tree(決策樹)

決策樹是一種基於樹狀結構進行數據分類和回歸的機器學習算法，廣泛應用於多種數據分析任務。該模型通過遞歸地將數據分割為子集合，逐步生成分類規則，最終形成一個樹狀的決策結構。由於其良好的解釋性和直觀性，決策樹在文本分類、特徵選擇和模式識別等領域中有著廣泛的應用。

在本次文本情感分類任務中，我們使用決策樹模型，目的是學習推文的文本特徵與情感標籤之間的對應關係，並利用學到的規則對未知推文進行分類。決策樹模型還能提供特徵的重要性分析，幫助我們理解哪些詞彙或短語對情感分類影響最大。

```
Training Accuracy: 0.9662874604149332
Training Loss: 0.0649
Classification Report:
              precision    recall  f1-score   support

     0.0         0.97        0.96        0.97        477674
     1.0         0.96        0.97        0.97        476600

 accuracy          0.97          0.97          0.97          954274
 macro avg         0.97          0.97          0.97          954274
weighted avg         0.97          0.97          0.97          954274
```

Figure 14: Decision tree train report

```
Testing Accuracy: 0.7048542560014084
Testing Loss: 9.5221
Classification Report:
              precision    recall  f1-score   support

     0         0.71        0.70        0.70        317768
     1         0.70        0.71        0.71        318416

 accuracy          0.70          0.70          0.70          636184
 macro avg         0.70          0.70          0.70          636184
weighted avg         0.70          0.70          0.70          636184
```

Figure 15: Decision tree test report

上面兩張分別展示了 Decision Tree 模型在測試集與訓練集上的性能結果，包括準確率、損失函數值，以及分類報告中的 Precision、Recall 和 F1-Score 指標。

在測試集上，模型的分類準確率為 **70.49%**，損失函數值為 **9.5221**，表現一般。分類報告顯示，負面情感（標籤 0）的 Precision 為 **71%**，Recall 為 **70%**，F1-Score 為 **70%**；正面情感（標籤 1）的

Precision 為 **70%**，Recall 為 **71%**，F1-Score 為 **71%**。整體來看，模型對兩類情感的分類表現較為均衡，但測試集的結果表明模型的泛化能力有限，分類準確率需要進一步提升。

相比之下，在訓練集上，模型的分類準確率達到了 **96.63%**，損失函數值僅為 **0.0649**，表現顯著優於測試集。負面情感（標籤 0）的 Precision、Recall 和 F1-Score 均為 **97%**，而正面情感（標籤 1）的 Precision 為 **96%**，Recall 和 F1-Score 同樣為 **97%**。這表明模型在訓練數據上表現非常出色，但也可能存在過擬合現象，因為測試集上的分類性能與訓練集相比有明顯差距。




Figure 16: Decision tree train 混淆矩陣




Figure 17: Decision tree test 混淆矩陣

上面兩張分別展示了 Decision Tree 模型在測試集與訓練集上的混淆矩陣結果，用以評估模型的分類性能。

在測試集中，負面情感（標籤 0）有 **123096** 條樣本被正確分類，但仍有 **35406** 條樣本被錯誤分類為正面情感（標籤 1）。正面情感（標籤 1）中，有 **120033** 條樣本被正確分類，而 **39557** 條樣本被錯誤分類為負面情感（標籤 0）。測試集結果顯示，模型對兩類情感的分類能力有限，錯誤分類數量較多，表明模型泛化能力不足。

在訓練集中，負面情感（標籤 0）有 **628075** 條樣本被正確分類，僅有 **8865** 條樣本被錯誤分類為

正面情感（標籤 1）。正面情感（標籤 1）中，有 **626450** 條樣本被正確分類，而僅有 **8976** 條樣本被錯誤分類為負面情感（標籤 0）。相比測試集，訓練集的分類結果顯示出極高的準確率，但這也可能是過擬合的跡象。

總體而言，Decision Tree 模型在訓練集上的高準確率顯示了其對已知數據的強學習能力，但測試集性能的明顯下降表明模型存在泛化能力不足的問題。未來可以通過限制模型深度或調整分裂參數來減少過擬合風險，並嘗試結合集成方法（如隨機森林）以提升分類準確性和穩定性。

8 CNN

卷積神經網絡（Convolutional Neural Network, CNN）是一種專為處理結構化數據（如圖像和序列數據）而設計的深度學習模型。在文本分類任務中，CNN 通過捕捉文本中局部特徵（如短語或詞序關係）來實現高效的分類。相較於傳統的機器學習方法，CNN 能夠自動學習數據中的特徵表示，並在大規模數據集上表現出卓越的性能。

在本次情感分析中，CNN 被用於學習推文中的詞序和短語特徵，以準確區分正面和負面的情感標籤。該模型的架構包括嵌入層（Embedding Layer）、卷積層（Convolutional Layer）、池化層（Pooling Layer）和全連接層（Fully Connected Layer）。嵌入層將文本轉換為低維詞向量表示，卷積層提取局部語義特徵，池化層進一步壓縮特徵，最終通過全連接層進行分類。

8.1 模型架構

```
# 定義 CNN 模型
model = Sequential([
    Conv1D(filters=128, kernel_size=3, activation='relu', input_shape=(3000, 1)),
    GlobalMaxPooling1D(),
    Dropout(0.5),
    Dense(64, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])
# 編譯模型
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
# 查看模型結構
model.summary()
```

該模型的主要層結構及功能描述如下：

- **Conv1D**：一維卷積層，用於提取輸入數據中的局部特徵。該層設置了 `filters=128`（128 個卷積核）和 `kernel_size=3`（核大小為 3），激活函數為 ReLU，並指定輸入形狀為 (3000, 1)。
- **GlobalMaxPooling1D**：全局最大池化層，用於壓縮特徵向量，提取每個特徵通道的最顯著值。
- **Dropout**：隨機丟棄部分神經元，用於防止模型過擬合。該層的丟棄比例設為 50%。
- **Dense**：全連接層，包含 64 個神經元，激活函數為 ReLU，用於進一步學習高層特徵。
- **Dense**（輸出層）：包含 1 個神經元，激活函數為 Sigmoid，適用於二元分類問題。

Layer (type)	Output Shape	Param #
conv1d_2 (Conv1D)	(None, 2998, 128)	512
global_max_pooling1d_2 (GlobalMaxPooling1D)	(None, 128)	0
dropout_4 (Dropout)	(None, 128)	0
dense_4 (Dense)	(None, 64)	8,256
dropout_5 (Dropout)	(None, 64)	0
dense_5 (Dense)	(None, 1)	65

Figure 18: CNN 架構圖

8.2 模型訓練與測試性能




Figure 19: CNN 準確率變化趨勢




Figure 20: CNN 損失值變化趨勢

上面兩張分別展示了 CNN 模型在訓練過程中的準確率與損失值的變化趨勢，用於分析模型在訓練集和測試集上的性能。

在第一張圖中，模型的訓練準確率從初始的 51.5% 緩慢提升到最終的 51.9%，顯示出模型在訓練過程中的學習能力。然而，測試準確率的起始值較高（約為 52.1%），在訓練過程中波動上升，但最終趨於平穩。訓練與測試準確率之間的差距表明模型的學習仍然受限，可能需要進一步優化。

在第二張圖中，訓練損失從初始值 0.6926 逐漸降低到約 0.6922，表明模型在訓練過程中逐步收斂。測試損失則從初始值 0.6921 降至約 0.6918，但整體波動較大，說明模型在測試數據上的穩定性尚需提升。

8.3 分類報告分析

分類報告:				
	precision	recall	f1-score	support
0.0	0.52	0.66	0.58	477674
1.0	0.53	0.38	0.44	476600
accuracy			0.52	954274
macro avg	0.52	0.52	0.51	954274
weighted avg	0.52	0.52	0.51	954274

Figure 21: CNN train report

分類報告:				
	precision	recall	f1-score	support
0	0.52	0.67	0.58	317768
1	0.53	0.38	0.44	318416
accuracy			0.52	636184
macro avg	0.52	0.52	0.51	636184
weighted avg	0.52	0.52	0.51	636184

Figure 22: CNN test report

上面兩張分別展示了 CNN 模型在測試集與訓練集上的分類報告結果。這些結果包含 Precision、Recall 和 F1-Score 等評估指標，用於衡量模型在二元分類任務中的性能。

在測試集上，模型的整體準確率為 **52%**。對於負面情感（標籤 0），Precision 為 **52%**，Recall 為 **67%**，F1-Score 為 **58%**。而對於正面情感（標籤 1），Precision 為 **53%**，Recall 為 **38%**，F1-Score 為 **44%**。結果顯示，模型在負面情感上的分類性能相對較好，但正面情感的 Recall 和 F1-Score 顯著偏低，表明模型對正面情感的區分能力不足。

在訓練集上，模型的分類性能與測試集非常相似，整體準確率同樣為 **52%**。負面情感（標籤 0）的 Precision 為 **52%**，Recall 為 **66%**，F1-Score 為 **58%**；而正面情感（標籤 1）的 Precision 為 **53%**，Recall 為 **38%**，F1-Score 為 **44%**。模型在訓練集和測試集上的性能幾乎一致，顯示其沒有明顯的過擬合現象，但模型的分類能力仍有限。

8.4 混淆矩陣分析




Figure 23: Decision tree train report




Figure 24: CNN test report

上面兩張分別展示了 CNN 模型在測試集和訓練集上的混淆矩陣結果，用以評估模型的分類能力。

在測試集上，負面情感（標籤 0）有 **211541** 條樣本被正確分類，但仍有 **106227** 條樣本被錯誤分類為正面情感（標籤 1）。而正面情感（標籤 1）中，僅有 **119965** 條樣本被正確分類，有 **198451** 條樣本被錯誤分類為負面情感（標籤 0）。這表明模型對正面情感的分類能力較弱，漏判數量明顯偏高。

在訓練集上，負面情感（標籤 0）有 **317369** 條樣本被正確分類，但仍有 **160305** 條樣本被錯誤分類為正面情感（標籤 1）。而正面情感（標籤 1）中，**178804** 條樣本被正確分類，有 **29796** 條樣本被錯誤分類為負面情感（標籤 0）。相比測試集，訓練集的分類性能稍有提升，說明模型在已知數據上的學習效果較好，但泛化能力仍然不足。

8.5 討論


總體而言，CNN 模型在負面情感的分類上表現優於正面情感，但整體性能偏低，準確率僅略高於隨機猜測（50%）。這可能是由於模型結構過於簡單，未能充分學習數據中的深層特徵，且正面情感的 Recall 偏低，存在較大的漏判問題。

爲了提升模型性能，可以採取以下改進措施：優化模型結構（如增加卷積層和神經元數量）、引入預訓練詞嵌入（如 Word2Vec 或 GloVe）提升特徵質量、使用數據增強技術擴大數據樣本多樣性，以及調整優化器與學習率以提升訓練效果。這些改進將有助於模型更好地學習情感分類任務中的特徵，並提高分類準確率。

9 應用展示與實際應用 UI

本研究的情感分析應用在 Hugging Face 平台，網址爲：<https://huggingface.co/spaces/Peter10355/twitter?logs=container>。Hugging Face 是一個強大的機器學習模型開發與部署平台，提供便捷的工具有於構建、分享和部署 NLP 應用。

下圖展示了應用的功能與介面。用戶可以輸入任意文本，並選擇 Naive Bayes、Decision Tree、Random Forest 或 CNN 等模型進行文本情感分類。例如，當輸入”I knew you could do it!”時，應用選用 Decision Tree 模型進行分類，結果顯示文本的情感爲 **Positive**（正面情感），且置信度爲 **91%**。



The screenshot displays a web interface for sentiment analysis. At the top, there is a header with the text "!!! Let's Analyze!!!". Below this, a text input field contains the sentence "I knew you could do it!". Underneath the input field, there is a section titled "Choose the Model" with four radio button options: "Naive Bayes", "Decision Tree" (which is selected), "Random Tree", and "CNN". A prominent "Run" button is located below the model selection. The output section, labeled "Output", shows the result "Positive" in a large font. Below this, a horizontal bar chart visualizes the confidence scores: "Positive" at 91% and "negative" at 9%.

Category	Confidence
Positive	91%
negative	9%

Figure 25: UI 展示範例